

1. Zaokružite tačne iskaze:

- ☒ a. Linearna regresija spada u nadgledano obučavanje.
- ☐ b. Linearnom regresijom predviđamo binarnu varijablu na osnovu kontinualne varijable.
- ☒ c. Linearna regresija modeluje odnos dve kontinualne varijable.
- ☐ d. Kod jednostruke linearne regresije modelujemo y na osnovu više ulaza x .
- ☒ e. Moguće je konstruisati model linearne regresije koristeći neuronsku mrežu.

2. Napišite formulu za jednostruku linearnu regresiju: $h_{\theta} = \theta_0 + \theta_1 x$. Zaokružite parametre ovog modela.

3. Zaokružite metrike adekvatne za evaluaciju regresionog modela: accuracy, cross-entropy loss, mean squared error, F-measure, R^2 .

4. Dat je sledeći trening skup:

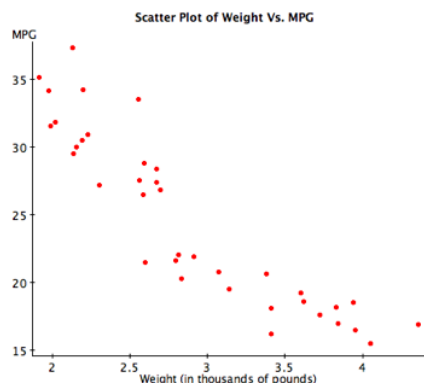
x	1	2	4	0
y	0.5	1	2	0

Ako biste ove podatke iskoristili za treniranje modela linearne regresije, koje vrednosti biste dobili za θ_0 i θ_1 ?

- (a) $\theta_0 = 0.5, \theta_1 = 0$ (b) $\theta_0 = 0.5, \theta_1 = 0.5$ (c) $\theta_0 = 1, \theta_1 = 0.5$ ☒ (d) $\theta_0 = 0, \theta_1 = 0.5$ (e) $\theta_0 = 1, \theta_1 = 1$

5. Ako imamo $\theta_0 = -1, \theta_1 = 0.5$, koliko je $h_{\theta}(4)$, a koliko $J(\theta_0, \theta_1)$?


6. Na grafiku skicirajte model i označite šta predstavljaju parametri modela.



MPG – Miles Per Gallon (koliko milja automobil pređe sa galonom goriva)

7. Minimalna vrednost funkcije greške linearne regresije je 0

a maksimalna ∞. Skicirajte tipičan oblik funkcije greške linearne regresije.



8. Neka je data funkcija greške $f(\theta_0, \theta_1)$ koja vraća realan broj i ima više lokalnih optimuma. Primenom gradijentnog spusta (GD) minimizujemo f i odabrali smo *learning rate* α . Zaokružite tačne iskaze:

- ☐ a. Čak i za veliko α , svaka iteracija GD će smanjiti vrednost f .
- ☒ b. Ako α ima previše nisku vrednost, GD će trebati puno vremena da konvergira.
- ☒ c. Ako su θ_0 i θ_1 u lokalnom optimumu, jedna iteracija GD neće promeniti njihovu vrednost.
- ☐ d. Ako su θ_0 i θ_1 inicijalizovani tako da važi $\theta_0 = \theta_1$, onda će nakon jedne iteracije GD, i dalje biti $\theta_0 = \theta_1$.
- ☒ e. Ako prve iteracije GD rezultuju uvećanjem vrednosti $f(\theta_0, \theta_1)$, verovatno smo postavili preveliko α .
- ☐ f. Bez obzira na inicijalizaciju θ_0 i θ_1 , uz dobar odabir α , GD će sigurno konvergirati u isti optimum.
- ☐ g. Postavka α na malu vrednost nije štetno i može samo da ubrza konvergenciju GD.

9. Neka smo pomoću GD uspeali da pronađemo minimum funkcije greške za model linearne regresije takav da važi $J(\theta_0, \theta_1) = 0$. Koji od sledećih iskaza su tačni:


- ☐ a. Da bi ovo bilo moguće, moramo imati $y^{(i)} = 0$ za svaki primer iz trening skupa.
- ☐ b. GD se "zaglavio" u lokalnom optimumu.
- ☐ c. Da bi ovo važilo, sigurno je $\theta_0 = 0$ i $\theta_1 = 0$, tako da model uvek vraća $h_{\theta}(x) = 0$.
- ☒ d. Trening skup je takav da svi primeri perfektno leže na pravoj liniji.
- ☐ e. Možemo perfektno da predvidimo vrednost y čak i za nove primere (koji nisu bili u trening skupu).

f. Ovo nije moguće – ne postoje vrednosti θ_0 i θ_1 za koje važi $J(\theta_0, \theta_1) = 0$.

10. ☒ Tačno ili netačno: Linearna regresija je osetljiva na *outlier-e*.

11. Šta je od sledećeg tačno za reziduala: ☒ (a) manje vrednosti su bolje (b) veće vrednosti su bolje (c) a ili b, zavisno od situacije (d) nijedan od ponuđenih odgovora nije tačan.

12. Koja od ilustrovanih rastojanja koristimo da bismo uklopili model linearne regresije?



- ☒ a) slika levo
☐ b) slika desno
☐ c) zavisi od situacije
☐ d) nijedan od ponuđenih načina.

13. Neka za model fitovan na podacima iz zadatka 6 važi da je $\theta_0 = 48.8$, a $\theta_1 = -8.37$.

a. Kako interpretirate vrednost obeležja θ_0 ?

ako vozilo nema tezinu ono prenosi 48.8 mpg, tj ako je x 0 onda je y 0o


b. Kako interpretirate vrednost obeležja θ_1 ?

na svakih 1000 lbs tezine mozemo precizirati 8.37 milja manje

14. Zaokružite tačne odgovore:




- ☐ a. Ne moramo birati nikakve parametre kada tražimo rešenje pomoću *Gradient Descent*.
☒ b. Ne moramo birati nikakve parametre kada tražimo rešenje pomoću *Normal Equation*.
☐ c. Preferiramo *Normal Equation* u slučaju velikog broja obeležja.
☐ d. *Normal Equation* je iterativan algoritam.
☐ e. Uvek možemo pronaći rešenje primenom *Normal Equation*.

15. Kako biste unapredili sledeći model?



izbacivanjem outlajera

16. Šta od navedenog je tačno za *learning rates* α_A , α_B i α_C koji su proizveli sledeće grafike?



a) $\alpha_A < \alpha_B < \alpha_C$

☒ b) $\alpha_B < \alpha_A < \alpha_C$

c) $\alpha_A = \alpha_B = \alpha_C$

d) Ne možemo zaključiti o a) – c) na osnovu grafika