

PCA: dekompozicija matrice Σ

- Kao što smo videli, možemo matricu kovarijanse predstaviti pomoću njenih sopstvenih vektora/vrednosti:

$$\Sigma v = \lambda v$$

- Ovo se može zapisati u matričnoj formi

$$\Sigma V = V L$$

gde je V matrica čije su kolone sopstveni vektori matrice Σ , a L je dijagonalna matrica čiji su ne-nula elementi odgovarajuće sopstvene vrednosti

- Odavde možemo Σ predstaviti kao funkciju njenih sopstvenih vrednosti i vektora:

$$\Sigma = V L V^{-1} = V L V^T$$

- Ova jednačina se zove **eigendecomposition of the covariance matrix** i može se dobiti postupkom koji se naziva **Singular Value Decomposition (SVD)**

Singular Value Decomposition (SVD)

- Svaka matrica (npr. matrica sa podacima $X \in \mathbb{R}^{N \times D}$) se može predstaviti kao proizvod tri matrice. Matrica $X \in \mathbb{R}^{N \times D}$:

$$X = USV^T$$

- Gde su $U = [u_1, \dots, u_D]$ i $V = [v_1, \dots, v_D]$ ortonormalne baze (za ovakve matrice važi da je inverz jednak transponovanoj matrici, tj. $V^T V = V V^T = 1$) za prostor redova i kolona matrice X
- a S je dijagonalna matrica sa elementima $\{\sigma_1, \dots, \sigma_D\}$

$$\begin{array}{|c|} \hline X \\ \hline (n \times d) \\ \hline \end{array} = \begin{array}{|c|} \hline U \\ \hline (n \times d) \\ \hline \end{array} \times \begin{array}{|c|} \hline \Sigma \\ \hline (d \times d) \\ \hline \end{array} \times \begin{array}{|c|} \hline V^T \\ \hline (d \times d) \\ \hline \end{array}$$

Singular Value Decomposition (SVD)

$$X = USV^T$$

- Ako je X matrica koja sadrži originalne podatke ($X \in \mathbb{R}^{N \times D}$):

$$X^T X = (USV^T)^T USV^T = VS^T U^T USV^T = VS^2 V^T$$

Singular Value Decomposition (SVD)

- Ako uporedimo jednačine:

$$X^T X = V S^2 V^T$$
$$\Sigma = X^T X = V L V^T$$

veoma su slične, osim što je $\sigma_i^2 = \lambda_i (i = 1, \dots, D)$

- Drugim rečima, SVD je identičan sa PCA
- Matricu V (koja u kolonama ima odgovarajuće sopstvene vektore) možemo pronaći direktnom primenom SVD na ulazne podatke X :

$$[U, S, V] = \text{svd}(X)$$

Prednosti i nedostaci SVD

- Dakle, PCA možemo primeniti:
 - izračunavanjem sopstvenih vrednosti matrice kovarijanse $\Sigma = X^T X$ ili
 - primenom SVD metode direktno na matricu podataka X
- Prednosti SVD:
 - numerička stabilnost (računanje $X^T X$ može da izazove gubitak preciznosti)
 - Ako je $D \gg N$ (više obeležja nego instanci), $\Sigma \in R^{D \times D}$ može biti veoma velika matrica