


1. Tačno ili netačno:
 - a. *Overfitting* je verovatniji kada postoji velika količina podataka za treniranje.
 - b. *Overfitting* je verovatniji ako imamo veliki broj obeležja.
 - c. *Overfitting* je verovatniji ako koristimo fleksibilan (kompleksan) model.
 - d. *Overfitting* je verovatniji ako smo uočili da su vrednosti parametara dobijenog modela male.
 - e. Verovatnije je da će model $y = \theta_0$ patiti od velike varijanse nego od velikog sistematskog odstupanja.
 - f. Za fiksni model, ako povećavamo trening skup, očekujemo da vrednosti parametara modela θ rastu.
2. Zamislite da ste na skupu podataka trenirali model linearne regresije 3. stepena polinoma i otkrili da su trening i test greška jednake 0 (odnosno, da se model savršeno uklapa u podatke).
 - a. Šta očekujete za polinom 4. stepena? (1) verovatnoća *overfitting*-a je velika; (2) verovatnoća *underfitting*-a je velika; (3) ne možemo reći; (4) nijedan od ponuđenih odgovora.
 - b. Šta očekujete za polinom 2. stepena? (1) verovatnoća *overfitting*-a je velika; (2) verovatnoća *underfitting*-a je velika; (3) ne možemo reći; (4) nijedan od ponuđenih odgovora.
 - c. Šta će se desiti ako koristite polinom 2. stepena? Sistematsko odstupanje će biti _____, varijansa će biti _____. (malo/veliko)
3. Na grafiku levo nacrtajte kako se ponaša (a) trening (b) test greška. Na grafiku desno nacrtajte kako se ponaša (a) trening i (b) test greška ako je **kompleksnost modela fiksirana**.



4. Na levom grafiku označite koji deo odgovara *overfitting*-u, a koji *underfitting*-u.
5. Na levom grafiku označite koji deo odgovara velikom sistematskom odstupanju, a koji varijansi.
6. Recimo da ste odabrali model optimalne kompleksnosti. Nakon toga ste identifikovali obeležje koje je veoma relevantno za rešavani zadatak. Šta očekujete da će se desiti ako dodate ovo obeležje u model? Trening greška će se _____. Greška na validacionom skupu će se _____. (uvećati/smanjiti)
7. Za svaku od tehniku naznačite da li imaju potencijal da **redukuju** sistematsko odstupanje (bias) i/ili varijansu:

	Bias	Varijansa
Uvećanje fleksibilnosti modela (npr. dodavanje slojeva/neurona u neuronsku mrežu)		
Primena <i>feature engineering</i> (npr. izmena ili dodavanje obeležja prema uvidima proisteklim iz analize grešaka modela)		
Selekcija obeležja da bi se smanjio broj obeležja		
<i>Early stopping</i> (zaustaviti <i>gradient descent</i> ranije, zasnovano na grešci validacionog skupa)		
Izmena modela (npr. izmena arhitekture neuronske mreže)		
Dodavanje više trening podataka		

8. Možemo li **linearnom** regresijom modelovati **kvadratnu** funkciju?
9. Trening skup služi za _____, validacioni skup služi za _____, a test skup služi za _____. Test skupom aproksimiramo _____ grešku.
10. Šta je „idealna“ stratifikacija, a šta obično radimo u praksi?
11. Kako biste stratifikovali podatke za regresiju, a kako za klasifikaciju?
12. Kada biste koristili podelu na trening i test skup, a kada unakrsnu validaciju?
13. Imamo skup podataka. Radi brže konvergencije *gradient descent*-a normalizovali smo vrednosti obeležja. Nakon toga smo podelili skup podataka na trening, validacioni i test skup. Da li smo sve dobro uradili?
14. U slučaju **višestruke** regresije, šta je ključna stvar o kojoj moramo voditi računa prilikom interpretacije parametara modela?
15. Kako enkodiramo nominalna, a kako ordinalna kategorička obeležja?

one-hot-enc ↳ one-hot-enc.
Label

16. Šta je potencijalni problem prethodnog pristupa? Kako biste ga rešili?
17. Multikolinearnost:
 - a. Nije problematična.
 - b. Nije problematična za performanse modela, ali troši računarske resurse.
 - c. Je nezgodna pri interpretaciji modela.
 - d. Može da se desi kod 1-hot-encoding-a.